



INSTITUTO UNIVERSITÁRIO DE LISBOA

Licenciatura em Ciência de Dados

3º ano 2º semestre - 2025/2026

Unidade Curricular:

Projeto Final Aplicado em Ciência de Dados

Previsão da Inflação em Portugal:

Modelos de Machine Learning

Grupo 11:

António Santos, nº 123434;

Gonçalo Henriques, nº 123422;

José Alberto nº 121959;

Pedro Santos, nº 123003.

Docente: Diana Mendes

Cliente: Ricardo Correia - Banco de Portugal

Lisboa, Junho de 2026

AGRADECIMENTOS

Aos pais e familiares de todos os elementos do Grupo 11 expressamos o nosso mais sincero reconhecimento pelo apoio incondicional ao longo de todo o percurso não só neste projeto, mas na licenciatura inteira. A vossa compreensão, incentivo constante e as condições que nos proporcionaram foram essenciais para que cada um de nós pudesse dedicar-se a este trabalho com empenho e responsabilidade.

Aos elementos que compõem o Grupo 11 fica também aqui o nosso reconhecimento. A construção deste projeto exigiu dedicação, resiliência e uma genuína capacidade de trabalho em equipa. É com orgulho que olhamos para o percurso que percorremos juntos. A cada elemento do grupo, obrigado pela entrega, pela complementaridade e por tornar este desafio numa experiência enriquecedora.

À Responsável pela Unidade Curricular, Professora Ana Maria Carvalho de Almeida, dirigimos um agradecimento especial pela forma como conduziu e coordenou o Projeto Final Aplicado em Ciência de Dados. A sua liderança pedagógica, aliada à exigência e ao rigor que sempre estiveram presentes nesta unidade curricular, contribuíram de forma determinante para elevar a qualidade do trabalho desenvolvido.

À nossa Orientadora, Professora Diana Elisabeta Aldea Mendes, deixamos um agradecimento muito sentido pelo acompanhamento próximo, pela disponibilidade permanente e pela partilha generosa de conhecimentos ao longo de todo o processo. A sua orientação foi um pilar fundamental deste projeto, guiando-nos nas opções metodológicas e ajudando-nos a transformar dificuldades em aprendizagens.

Aos restantes docentes da Unidade Curricular, Professores Fernando Batista, José Gonçalves Dias, Luís Nunes e Maria Teresa Delgado Calapez, expressamos o nosso reconhecimento pelo contributo que cada um, à sua forma, trouxe para o enriquecimento deste nosso percurso formativo.

Ao Banco de Portugal, na presença do Dr. Ricardo Correia, expressamos o nosso sincero agradecimento pela disponibilidade e pela confiança depositada neste grupo ao propor um desafio com relevância económica real. O problema colocado foi uma fonte de motivação constante ao longo de todo o projeto, e o enquadramento prático que proporcionou enriqueceu significativamente a nossa abordagem e o nosso crescimento enquanto futuros cientistas de dados.

Por fim, a todos os colegas da Licenciatura em Ciência de Dados, o nosso obrigado pelo espírito de entreatajuda e pelo ambiente de colaboração que tornou este percurso mais rico e mais divertido. Crescemos enquanto cientistas de dados também, um bocado, graças a todos os nossos colegas de curso.

A todos, o nosso mais profundo e sincero obrigado.

ÍNDICE

Agradecimentos.....	II
1. Introdução.....	1
1.1 Contextualização	1
1.2 Estado da Arte	2
1.3 Questões de investigação	3
1.4 Metodologia e estrutura do relatório	3
2. Descrição e compreensão dos dados	4
2.1 Fontes e recolha.....	4
2.2 Variável alvo e comportamento histórico.....	5
2.3 Síntese da análise exploratória	6
3. Preparação dos Dados	8
3.1 Valores Omissos	8
3.2 Estacionarização.....	9
3.3 Seleção de Variáveis.....	9
3.4 Tratamento de <i>Outliers</i>	10
3.5 Seleção de desfasamentos e <i>Pipeline</i>	10
4. Técnicas e Métodos	12
4.1 Estratégia de avaliação	12
4.2 Modelos econométricos.....	13
4.3 Modelos de <i>Machine Learning</i>	13
4.4 Otimização de hiperparâmetros.....	15
4.5 Deployment	16
5. Discussão de Resultados	17
5.1 Comparação Global.....	17
5.2 Modelo Vencedor	18

5.3 Resposta às Questões de Investigação	19
6. Conclusões e Recomendações.....	21
Referências Bibliográficas	23
Fontes dos Dados	25
Apêndice A — Revisão de literatura	26
A.1 Abordagens tradicionais e fundamentos teóricos	26
A.2 Machine Learning na previsão da inflação.....	27
A.3 Estudos empíricos de referência.....	28
A.4 Posicionamento do estudo	28
Apêndice B — Análise exploratória.....	30
B.1 Análise da variável alvo.....	30
B.2 Análise de correlação contemporânea em nível	31
B.3 Análise de formas funcionais.....	32
B.4 Análise bivariada de variáveis seleccionadas	33
B.5 Análise de desfasamentos temporais	34
B.6 Análise de variáveis com comportamento específico	35
Apêndice C — Detalhes de preparação.....	37
C.1 Interpolação das variáveis trimestrais.....	37
C.2 Tratamento de <i>ragged edges</i> (Auto-ARIMA)	37
C.3 Estacionarização de variáveis sem código predefinido	38
C.4 Desfasamentos seleccionados pelo <i>Lasso</i>	39
Apêndice D — Variáveis seleccionadas.....	41
D.1 Variáveis seleccionadas por Causalidade de Granger	41
D.2 Variáveis seleccionadas por teoria económica	42
Apêndice E — Resultados detalhados	43
E.1 Modelo ARIMA	43

E.1.1 Identificação da ordem.....	43
E.1.2 Análise de resíduos	44
E.1.3 Previsões no conjunto de teste	45
E.2 Modelo VAR.....	46
E.3 Modelo CC-VAR	47
E.4 Melhores modelos de ML por grupo de variáveis	47
Apêndice F — Otimização do VAR e CC-VAR.....	49
F.1 Modelo VAR.....	49
F.2 Modelo CC-VAR.....	50
G — Navegação no dashboard (deployment)	51


1. INTRODUÇÃO

O presente relatório foi desenvolvido no âmbito da Unidade Curricular de Projeto Final Aplicado em Ciência de Dados, do 2.º Semestre do ano letivo 2025/2026 do Curso de Licenciatura em Ciência de Dados, tendo como entidade cliente o Banco de Portugal. O tema em estudo consiste na previsão da taxa de inflação homóloga em Portugal, a partir de um conjunto de variáveis macroeconómicas nacionais, europeias e norte-americanas, comparando modelos econométricos clássicos com modelos de *Machine Learning (ML)*. Além da modelação, o trabalho disponibiliza os resultados numa aplicação *web* que permite a qualquer interessado explorar os modelos desenvolvidos, as variáveis utilizadas e os cenários implementados.

1.1 Contextualização

A inflação é um dos indicadores macroeconómicos com maior impacto no quotidiano: condiciona o poder de compra das famílias, as decisões de consumo e de investimento das empresas e a própria condução da política monetária (Banco de Portugal, 2019). Em Portugal é medida pelo Índice de Preços no Consumidor (IPC), calculado mensalmente pelo Instituto Nacional de Estatística. O objeto deste estudo é a respetiva taxa de variação homóloga, isto é, a variação percentual do nível geral de preços face ao mesmo mês do ano anterior. O Banco Central Europeu fixa como objetivo de médio prazo uma inflação próxima de 2% (Banco Central Europeu, 2026), referência que enquadra a leitura de toda a série.

A previsão desta variável é, contudo, difícil, pois a inflação resulta da interação de fatores de procura e de oferta, custos de produção, condições monetárias, choques externos e incerteza política, muitas vezes com relações não-lineares e efeitos de desfasamento no tempo. Os últimos 25 anos ilustram bem esta dinâmica: a deflação associada à crise financeira global, com um mínimo de -1,7% (*MadreMedia & Lusa*, 2018); o pico de cerca de 10% em 2022, na sequência da pandemia de COVID-19 e da invasão da Ucrânia (*Diehn*, 2022); e a desinflação gradual que voltou a aproximar a série do objetivo de 2%, seguida por uma estabilização até ao final da série (Figura 1.1). É uma série dominada por choques e sem sazonalidade regular, o que torna a escolha da abordagem de modelação uma questão em aberto que motiva o presente estudo.



1.2 Estado da Arte

Durante décadas, a previsão da inflação apoiou-se em modelos econométricos. Os univariados, como o *AutoRegressive Integrated Moving Average (ARIMA)*, servem habitualmente de referência por captarem bem a inércia da série, que a literatura reconhece como um dos principais preditores da inflação. Os multivariados, como o *Vector Autoregression (VAR)* e o *Autoregressive Distributed Lag (ARDL)*, permitem ainda relacionar a inflação com outros indicadores macroeconómicos. A escolha desses indicadores assenta em teoria económica, sobretudo na *New Keynesian Phillips Curve (NKPC)*, que liga a inflação aos custos das empresas e às expectativas, embora Lagoa (2017) demonstre que a *NKPC*, por si só, não explica os diferenciais da inflação entre os países da Zona Euro sem o contributo do Modelo de Competição Imperfeita (*ICM*). Como estes modelos assumem relações lineares e tornam-se instáveis em períodos de choques, procuram-se alternativas mais flexíveis, um percurso que Ramos (2021) acompanha das metodologias clássicas ao *deep learning* na modelação de séries económico-financeiras.

É nesse contexto que os métodos de *ML* ganham relevância, pois, ao não imporem uma forma funcional, captam relações não-lineares e lidam com um número elevado de preditores. Oancea et al. (2025) confirmam que estes métodos superam o *ARDL* na previsão da inflação e, que a vantagem aumenta quando incorporam indicadores de sentimento e de incerteza. É esse tipo de informação, que escapa aos modelos tradicionais em períodos voláteis, que o índice de incerteza política, desenvolvido por Morão (2024), procura medir para Portugal. O presente estudo segue abordagens como a de Santos (2019), que aplicou técnicas de *ML* à previsão da inflação portuguesa, recorrendo a uma base de dados mais ampla, composta sobretudo por variáveis portuguesas e complementada por indicadores europeus (Barigozzi et al., 2024) e norte-americanos

(McCracken *et al.*, 2016). O [Apêndice A](#) apresenta uma revisão mais detalhada da literatura.

1.3 Questões de investigação

De toda a compreensão do domínio e da revisão detalhada da literatura, foram levantadas as três questões que orientaram o trabalho desenvolvido. A primeira é se os modelos de *ML* superam os modelos econométricos tradicionais na previsão da inflação em Portugal. A segunda é quais os principais fatores e variáveis determinantes da dinâmica inflacionista portuguesa. Por fim, a terceira é se a inclusão de indicadores de sentimento e de incerteza económica, em particular o índice de incerteza de política económica e o indicador de confiança do consumidor, melhora o desempenho preditivo dos modelos.

1.4 Metodologia e estrutura do relatório

A investigação seguiu a metodologia *CRISP-DM* (*Cross-Industry Standard Process for Data Mining*), que estruturou o trabalho desde a compreensão do domínio e dos dados, passando pela preparação e pela modelação, até à avaliação e ao *deployment*. Foram integradas seis fontes de dados num painel mensal de Janeiro de 2000 a Outubro de 2025, sobre o qual se treinaram e compararam modelos econométricos (*ARIMA*, *VAR* e *CC-VAR*) e de *ML* (*Ridge*, *Random Forest* e *LightGBM*), avaliados num período de teste reservado.

O restante relatório está organizado da seguinte forma. O Capítulo 2 descreve e caracteriza os dados, incluindo a síntese da análise exploratória. O Capítulo 3 detalha a preparação dos dados, da imputação à seleção de variáveis e de desfasamentos. O Capítulo 4 apresenta as técnicas e métodos de modelação, a estratégia de avaliação e o *deployment*. O Capítulo 5 discute os resultados e responde às questões de investigação. O Capítulo 6 conclui com as implicações para o Banco de Portugal e as direções de trabalho futuro.

2. DESCRIÇÃO E COMPREENSÃO DOS DADOS

A previsão da inflação depende, em primeiro lugar, da qualidade e da abrangência dos dados disponíveis. Para captar a dinâmica inflacionista portuguesa, que resulta da interação entre fatores internos, pressões europeias e choques globais, o estudo integra seis fontes heterogêneas, combinando indicadores nacionais com séries da Zona Euro e da economia norte-americana, num painel de 310 meses.

2.1 Fontes e recolha

Do *BPstat* (*Estatísticas do Banco de Portugal*) foram retiradas: a variável alvo, a taxa de variação homóloga do Índice de Preços no Consumidor (IPC) e a taxa de câmbio histórica de dólares norte-americanos (*USD*) para euros (*EUR*), utilizada na conversão de variáveis monetárias (Banco de Portugal, 2026). Da base de dados EA-MD-QD (*Euro Area, Monthly and Quarterly Database*) foram obtidos indicadores macroeconómicos mensais e trimestrais relativos a Portugal e à Zona Euro (Barigozzi et al., 2026). Da *FRED-MD* (*Federal Reserve Economic Data, Monthly Database*) recolheram-se indicadores da economia norte-americana com impacto global (McCracken & Ng, 2016). O *EPU* (*Economic Policy Uncertainty Index*) para Portugal foi obtido a partir de um artigo que desenvolve e publica este índice de incerteza de política económica para o contexto nacional (Morão, 2024). O *PPI* (*Producer Price Index*, Índice de Preços no Produtor) para Portugal foi obtido através do *Eurostat* (*Eurostat*, 2026), com imputação manual para o período inicial. Da *OCDE* (Organização para a Cooperação e Desenvolvimento Económico) obteve-se a taxa de desemprego mensal em Portugal para a população com 15 ou mais anos (*OCDE*, 2026).

O *dataset* final integra 310 observações mensais (jan/2000–out/2025) e 119 variáveis candidatas. Na fase de *feature engineering*, o preço do petróleo foi convertido de *USD* para *EUR* através da taxa de câmbio histórica. A Tabela 2.1 resume as seis fontes e o [Apêndice B](#) apresenta a análise exploratória completa.

Fonte	Período	Freq.	Variáveis principais
<i>BPstat</i>	Jan/2000–Out/2025	Mensal	IPC (variável alvo), taxa de câmbio <i>EUR/USD</i>
<i>EA-MD-QD</i>	Jan/2000–Out/2025	Mensal e trimestral	HICP, produção industrial, desemprego, confiança, câmbio
<i>FRED-MD</i>	Jan/2000–Out/2025	Mensal	<i>Treasury yields</i> , petróleo, <i>CPI commodities</i> , PCEPI
<i>EPU</i> Portugal	Jan/2000–Out/2025	Mensal	Índice de incerteza de política económica
<i>EconDB</i>	Jan/2000–Out/2025	Mensal	PPI Portugal
<i>OCDE</i>	Jan/2000–Out/2025	Mensal	Taxa de desemprego ≥ 15 anos (Portugal)

Tabela 2.1 — Quadro-resumo das seis fontes de dados

A partição foi feita cronologicamente: o conjunto de treino agrega de jan/2000 a jun/2023 (282 obs., 91%) e o conjunto de teste corresponde a jul/2023 até out/2025 (28 obs., 9%), garantindo ausência de *data leakage*. O conjunto de treino cobre os principais regimes macroeconómicos da série, desde o crescimento moderado e a deflação pós-crise financeira à recuperação e ao pico inflacionista de 2022, expondo os modelos à heterogeneidade histórica da variável alvo. O conjunto de teste coincide com a fase de desinflação gradual de 2023–2025, um regime distinto do treino e, por isso, uma avaliação mais exigente da capacidade de generalização.

2.2 Variável alvo e comportamento histórico

A variável alvo é a taxa de variação homóloga do IPC em Portugal, medida mensalmente pelo Instituto Nacional de Estatística (INE). O comportamento histórico da série e os episódios que a marcaram foram descritos na [secção 1.1](#). As estatísticas descritivas revelam uma média de 2,2%, próxima do objetivo do Banco Central Europeu (BCE) de 2% a médio prazo, com um desvio-padrão de 1,97%, um mínimo de –1,7% e um máximo de 10,1%.

Métrica	Observações	Média	Desvio-padrão	Mínimo	Máximo
Valor	310	2.2%	1.97p.p	-1.7%	10.1%


Tabela 2.2 — Estatísticas descritivas da variável alvo

O teste *Augmented Dickey-Fuller (ADF)* devolveu um *p-value* de 0,09, confirmando a não-estacionariedade da série em nível e a necessidade de diferenciação nos modelos econométricos. A série não apresenta tendência determinística nem sazonalidade.

Os principais episódios que marcaram a série ao longo deste período foram descritos na [secção 1.1](#).

2.3 Síntese da análise exploratória


A série tem forte inércia inflacionista: a autocorrelação no primeiro *lag* é de 0,98 e decai gradualmente até 0,4 no décimo segundo *lag*. A inflação presente é determinada, em grande parte, pela inflação recente, o que justifica a inclusão dos valores desfasados da variável alvo como preditores nos modelos de *ML*.



A maioria das variáveis explicativas tem relações não-lineares com a inflação, assumindo frequentemente formas cúbicas ou quadráticas, o que reforça a opção por modelos de *ML* em detrimento de abordagens estritamente lineares.

O *PPI* regista uma correlação de *Pearson* de 0,60 em nível e de 0,72 com um desfasamento de 5 meses, o que reflete a demora na transmissão dos custos de produção

ao consumidor final. O preço do petróleo antecipa a inflação com um desfasamento de 4 a 6 meses, consistente com a transmissão gradual dos custos energéticos ao longo da cadeia de distribuição. Estes padrões sustentam a inclusão de *lags* das variáveis explicativas nos modelos preditivos.



3. PREPARAÇÃO DOS DADOS

Antes de avançar para a modelação, foi necessário preparar os dados para resolver os problemas de qualidade identificados nas fontes. Para evitar *data leakage*, o *dataset* foi dividido cronologicamente por se tratar de uma série temporal, a divisão não foi aleatória, mas temporal. O conjunto de treino cobre janeiro de 2000 a junho de 2023 (91%) e o de teste vai de julho de 2023 a outubro de 2025 (9%). A proporção 91/9 foi intencional, pois garantiu que o pico inflacionista de 2022 ficasse integralmente no conjunto de treino, expondo os modelos ao choque mais extremo da série antes de serem avaliados.


A *pipeline* desenvolvida estruturou a preparação em cinco etapas sequenciais com aplicação seletiva consoante a família de modelos. Todos os tratamentos abaixo descritos foram realizados inicialmente apenas sobre o conjunto de treino.

3.1 Valores Omissos

Um dos primeiros problemas identificados foi a coexistência de séries mensais e trimestrais, resultando em *missing values* (*NaN*) para as variáveis de frequência trimestral (*EA-QD*) quando alinhadas com as de frequência mensal. Numa primeira etapa utilizou-se a interpolação interna para resolver este problema, testando-se doze métodos por variável e selecionou-se aquele que minimizava a diferença entre as médias da série original e da série tratada.

No entanto, apenas esta técnica não foi suficiente para tratar de todos os *NaN* devido as *ragged edges*, que correspondem aos valores em falta que surgem quando as observações mais recentes de algumas séries trimestrais correspondem aos meses entre os trimestres. Para tal, foi necessário recorrer a técnicas como o *Expectation Maximization* (*EM*) e o *Auto-ARIMA* tendo sido utilizado o *Auto-ARIMA* no final pelo facto do *EM* imputar valores que não correspondem à realidade da dinâmica da série.

Estas técnicas foram implementadas de modo a conservar a estrutura original dos dados. A validação foi feita por comparação das funções de densidade de probabilidade das séries originais e tratadas, confirmando que os valores imputados preservam a estrutura original dos dados (Figura 3.1).



3.2 Estacionarização

Os modelos econométricos clássicos pressupõem a não existência de raízes unitárias (estacionaridade das séries), com média e variância estável ao longo do tempo. As transformações necessárias foram determinadas a partir das bases de dados da *FRED-MD* (McCracken & Ng, 2016) e pela *EA-MD-QD* (Barigozzi *et al.*, 2024), validados pelos testes *ADF* e *KPSS*. A variável alvo é não estacionária ([secção 2.2](#)), tendo sofrido uma diferenciação de primeira ordem ($d=1$).

Das variáveis que não pertenciam a nenhuma das bases de dados com as transformações predefinidas, foram feitas as análises e, para o *PPI* que apresentava valores negativos (impedindo a logaritmização), a solução foi o $\log(\text{PPI} + 6,3)$, onde 6,3 corresponde ao valor absoluto mínimo da série acrescido de 0,1, que produz uma série estacionária segundo o *KPSS*. As restantes encontram-se em maior detalhe no [Apêndice C](#).

3.3 Seleção de Variáveis

Das 119 variáveis candidatas, foi necessário selecionar um subconjunto operacional. Um número excessivo de variáveis pode aumentar a complexidade do modelo, favorecer o *overfitting*, elevar os custos computacionais e dificultar a generalização. Assim, a seleção das variáveis a utilizar na fase de modelação assentou em dois critérios complementares: computacional e a teoria económica.

Para a seleção computacional, foram explorados diversos métodos: correlação de *Pearson*, *Stepwise Models*, *SelectKBest*, *RandomForest*, *Ridge*, *Lasso* e Causalidade de *Granger* (*Scikit-learn*, *s.d.*). O critério final foi a Causalidade de *Granger* ($\text{maxlag}=6$, $\rho=0,05$), por ser o único que teste causalidade preditiva no sentido temporal sobre as

variáveis estacionarizadas, enquanto os restantes baseiam-se em associações contemporâneas, vulneráveis a relações espúrias. A implementação deste método selecionou 13 variáveis computacionalmente em nível.

A seleção teórica assentou em dois domínios principais económicos: a *New Keynesian Phillips Curve* (NKPC) e o Modelo de Competição Imperfeita (ICM), abordados anteriormente e no [Apêndice A](#). Estas teorias apontam para variáveis ligadas ao mercado de trabalho, à atividade real, ao comércio externo e à incerteza política económica, concretizando em 8 variáveis teóricas. O conjunto final obteve assim 21 variáveis explicativas (13 computacionais e 8 teóricas) detalhadas no [Apêndice D](#).

3.4 Tratamento de *Outliers*

Este passo aplicou-se exclusivamente aos modelos ML, enquanto os modelos econométricos clássicos utilizam as séries transformadas sem estandardização adicional.

O conjunto das 21 variáveis inclui grandezas de natureza distinta: variáveis monetárias, indicadores e percentagens, todas em escalas diferentes. Para evitar que variáveis com maior magnitude tivessem uma influência desproporcional no processo de aprendizagem dos modelos, em detrimento de variáveis com menor escala, mas potencialmente mais relevantes, foi necessário a normalização. Antes de definir o método de normalização, foi analisada a presença de valores atípicos (*outliers*) pelo método do Intervalo Interquartil (IQR), identificado em 22 séries. Estes valores correspondem maioritariamente a acontecimentos económicos, como a crise financeira 2008, a pandemia de COVID-19 e a invasão da Ucrânia pela Rússia em 2022, e por isso a estratégia não foi eliminá-los, mas sim escolher um método de normalização que reduzisse a sua influência sem apagar a informação que contêm.

O *StandardScaler*, baseado na média e no desvio-padrão, é sensível a valores extremos e não cumpre esse requisito. Por isso, foi aplicado apenas às séries sem *outliers* identificados. Para as restantes, o tratamento foi feito com o *QuantileTransformer*, uma transformação robusta à presença de valores extremos que reduz o peso dos episódios atípicos sem os eliminar.

3.5 Seleção de desfasamentos e *Pipeline*

Para que os modelos ML captassem a dinâmica temporal das séries, foi necessário incorporar informação relativa aos valores passados de cada variável. Para cada uma das

21 variáveis explicativas seleccionadas, foram gerados os doze primeiros *lags*, considerando como potenciais preditores a variável em nível e os seus *lags*. Sobre este conjunto foi aplicada a regressão *Lasso* (*Least Absolute Shrinkage and Selection Operator*), que utiliza a regularização *L1*. Esta penaliza a magnitude dos coeficientes e promove a seleção automática de variáveis ao forçar coeficientes pouco relevantes a assumir o valor zero. Os 61 *lags* cujos coeficientes permaneceram não nulos foram retidos para a modelação.

Todos estes passos foram incorporados em um *Pipeline* (*pipeline_datapreparation.py*), que garante reprodutibilidade e ausência de *data leakage*: os parâmetros de cada técnica do tratamento são ajustados exclusivamente no conjunto de treino e aplicados ao conjunto de teste. Ambas as famílias dos modelos partem das séries integradas, com os *NaN* tratados e variáveis seleccionadas. A partir daí divergem: os modelos clássicos (ARIMA, VAR, CC-VAR) recebem as séries estacionarizadas ([secção 3.2](#)), enquanto os de ML recebem tratamento de *outliers* e desfasamentos ([secção 3.4](#) e [3.5](#)). Os detalhes deste capítulo constam no [Apêndice C](#).

4. TÉCNICAS E MÉTODOS

A estratégia de modelação assentou na comparação direta entre os dois paradigmas distintos: modelos econométricos clássicos, que incorporam pressupostos sobre a estrutura das séries temporais, e modelos de *Machine Learning* (ML), que aprendem padrões diretamente dos dados sem impor uma forma funcional. Todos os modelos foram desenvolvidos e avaliados nas mesmas condições, sobre os mesmos dados e com as mesmas métricas. O capítulo cobre a estratégia da avaliação, os modelos econométricos e de ML, o processo de otimização de hiperparâmetros e aquilo que foi o processo de *deployment* dos modelos.

4.1 Estratégia de avaliação

Todos os modelos foram treinados sobre o conjunto de treino (jan/2000 – jun/2023) e avaliados no conjunto de teste (jul/2023 – out/2025), sem acesso aos dados de teste durante o desenvolvimento. As métricas de avaliação foram o *RMSE* (*Root Mean Squared Error*), *MAE* (*Mean Absolute Error*) e *WAPE* (*Weighted Absolute Percentage Error*), uma vez que cada uma fornece uma perspetiva complementar sobre a qualidade das previsões. O *RMSE* foi incluído por ser expresso na mesma unidade da variável alvo e por penalizar mais fortemente erros de maior magnitude. No entanto, esta característica torna-o mais sensível à presença de *outliers*. Por esse motivo, foi utilizado o *MAE*, que, por se basear nos erros absolutos, é menos influenciado por valores extremos, fornecendo uma medida mais robusta do erro médio de previsão. Adicionalmente, recorreu-se ao *WAPE* para expressar o erro de forma relativa à magnitude dos valores observados, facilitando a interpretação do impacto prático.

Para os diferentes modelos construídos foi avaliado também a possibilidade de existência de *overfitting* comparando visualmente o desempenho dos modelos nos conjuntos de treino e teste, e através da regra empírica de um aumento de 15% para o conjunto de teste. Os modelos finais foram comparados também utilizando *RMSE* e *MAE* relativos face ao modelo *Naïve* que utiliza a média do conjunto de treino como previsão de modo a se ter também uma perceção do ganho do modelo face a esta média:

$$rRMSE_{model} = \frac{RMSE_{model}}{RMSE_{média}} \times 100 \quad , \quad rMAE_{model} = \frac{MAE_{model}}{MAE_{média}} \times 100$$

4.2 Modelos econométricos

Os modelos econométricos foram ajustados sobre as séries estacionarizadas, sem normalização adicional.

O *ARIMA* (*AutoRegressive Integrated Moving Average*) foi utilizado como modelo *benchmark* univariado. A ordem foi selecionada por *grid search* (*Scikit-learn*, *s.d.*) minimizando os critérios de informação *Akaike* (*AIC*), *AICc* e *Bayesian* (*BIC*), tendo sido selecionado o modelo *ARIMA*(0,1,4). As previsões *multi-step* foram geradas de forma recursiva em blocos de 4 passos, com atualização pelos valores reais entre blocos.

O *VAR* (*Vector AutoRegression*) é um modelo multivariado que trata a variável alvo e um conjunto de variáveis explicativas como um sistema de equações interdependentes, onde cada variável depende dos valores passados de todas as outras. Foram testados três subconjuntos de variáveis (teóricas, computacionais e *best features*), com o número de *lags* e o tipo de tendência determinística otimizados por *Optuna* (300 *trials*) com validação *walk-forward* de 3 *folds* e horizonte de 12 meses, exclusivamente sobre o conjunto de treino. O melhor resultado foi obtido com as variáveis teóricas (lag=1, tendência constante e linear).

O *CC-VAR* (*Common Component VAR*) aplica previamente uma Análise de Componentes Principais (*PCA*) às variáveis explicativas, substituindo-as pelos componentes que captam a maior parte da sua variância, e ajusta depois o *VAR* sobre a variável alvo e esses componentes. A variância explicada retida, o número de *lags* e o tipo de tendência foram otimizados com *Optuna* (300 *trials*) combinado com validação *walk-forward* (3 *folds*, horizonte de 12 meses). Para garantir que o resultado não dependia de uma inicialização favorável, foram testadas 500 *seeds* com paragem antecipada ao atingir 15 *trials* consecutivos sem melhoria. O melhor modelo usou as variáveis teóricas com 4 componentes principais que explicam 82% da variância, lag=1 e tendência constante e linear.

A análise mais profunda destes modelos encontra-se no [Apêndice E](#).

4.3 Modelos de *Machine Learning*

Durante a fase do estudo da arte alguns modelos se repetiam a cada artigo lido sobre a utilização de técnicas de *ML* para a previsão da inflação, estes modelos foram o

Random Forest e o *LightGBM*, por se verificar isto estes modelos foram selecionados para fazerem parte deste estudo.

Na secção 3.3 foram mencionados métodos utilizados para a seleção das variáveis a serem utilizados na fase de modelação e na lista estava o *Ridge* que é um modelo de regressão que utiliza a regularização $L2$, ele não foi utilizado naquela fase por se manifestar como não totalmente adequado tal como os outros métodos não selecionados.

Entretanto, este modelo surge novamente nesta fase por ter sido também um dos selecionados para a previsão da inflação. Esta seleção deve-se ao facto deste modelo ser recomendado quando se pretende reduzir *overfitting*, um risco que se verifica para este estudo tendo em conta o número elevado de variáveis a serem utilizadas para a construção dos modelos.

O *Random Forest* foi utilizado com duas versões diferentes, uma com os erros quadrados como critério de medida da qualidade do *split* por permitir reduzir a variância dos dados e a outra com os erros absolutos como critério por ser menos sensível a presença de *outliers*, que como já foi dito foi algo verificado na variável alvo deste estudo.

Tal como se verificou nos modelos clássicos o processo de modelação nos modelos de *ML* também se dividiu entre as variáveis teóricas e computacionais, entretanto, os processos para cada grupo de variáveis foram exatamente os mesmos. Estes processos incluem o treinamento dos modelos adicionando um nível de *lags* a cada iteração, avaliar no conjunto de teste e guardar os resultados numa tabela.

Com esta abordagem foram treinados aproximadamente 40 modelos por grupo de variáveis, para cada um destes grupos os modelos foram ordenados com base no *rank* médio das diferentes métricas – foram feitos *ranks* dos modelos por métricas e calculadas em seguida a média dos *ranks* por modelo. Apesar dos processos terem sido os mesmos os resultados foram totalmente diferentes.

Para o grupo das variáveis teóricas o modelo que ocupou a primeira posição do *rank* foi o *LightGBM* com até 10 *lags* e para o grupo das variáveis computacionais foi o *Ridge* com até 12 *lags*. No [apêndice E](#) encontra-se o top 5 de cada subconjunto. Selecionados estes dois modelos foram verificados em seguida as *features* mais importantes de cada modelo, para as variáveis teóricas foram selecionadas 5 variáveis e para as computacionais foram 9, e estas foram selecionadas para construir novos modelos que agora com os dois subconjuntos unificados com um total de 14 variáveis.

Foram novamente construídos modelos, desta vez sem o *rank* por serem poucos modelos dado que já não foram adicionados novos níveis de *lags*, no entanto, esta abordagem apenas permitiu melhorar a performance do *Ridge* e não a do *LighGBM* (Tabela 4.3) que teve o seu melhor desempenho com as variáveis teóricas. O modelo que teve um ganho maior foi o *Ridge* e este foi então selecionado como o melhor modelo de *ML*.

		Modelos			
		Ridge	RF - MSE	RF - MAE	LGBMRegressor
Métricas	RMSE	0,36	2,15	1,37	0,62
	MAE	0,31	1,99	1,25	0,51
	WAPE	0,13	0,82	0,51	0,21
		Modelos			
		Ridge	RF - MSE	RF - MAE	LGBMRegressor
-	RMSE	0,36	2,15	1,37	0,62
Métricas	MAE	0,31	1,99	1,25	0,51
-	WAPE	0,13	0,82	0,51	0,21

Métrica	Ridge	RF - MSE	RF - MAE		LightGBM
RMSE	0,36	2,15	1,37	0,62	
MAE	0,31	1,99	1,25	0,51	
WAPE	0,13	0,82	0,51	0,21	

Tabela 4.3 – Desempenho dos modelos de *ML*

4.4 Otimização de hiperparâmetros

Ridge: A otimização foi explorada com duas estratégias de validação cruzada (*split* fixo 80/20 e *walk-forward* com 3 *folds* e horizonte de 12 meses) e quatro funções objetivo (*RMSE*, *MAE*, *WAPE* e média dos três), totalizando 8 combinações. Nenhuma superou o *Ridge* com $\alpha=1,0$ por omissão. O *split* fixo selecionou α s entre 0,12 e 0,17, com *RMSE* teste entre 0,49 e 0,57. O *walk-forward* selecionou α s próximos de zero (0,002–0,005), reduzindo a regularização e agravando o sobreajustamento (*RMSE* teste $>1,10$). Uma pesquisa em grelha sobre 60 valores de α confirmou que $\alpha=0,76$ produz resultados idênticos ao *default* ($RMSE=0,36$, $MAE=0,31$), o que indica que o α ótimo está na vizinhança de 1,0.

VAR e CC-VAR: A otimização foi feita por *Optuna* com validação *walk-forward*. Os detalhes das configurações testadas e os resultados por subconjunto constam do [Apêndice F](#).

4.5 Deployment

Após a seleção dos modelos finais tanto de *ML* quanto modelos clássicos foi construída uma *FastAPI* utilizando o *Framework Flask* do *Python* para o deployment dos modelos treinados. Esta *FastAPI* permite, entretanto, realizar previsões com os modelos com base em cenários predefinidos e dá ainda a liberdade de personalização dos mesmos. Permite ainda ter acesso aos coeficientes de cada variável dos modelos de *ML*, podendo assim ser possível explicar as previsões dos mesmos.

A *FastAPI* dá ainda acesso às variáveis utilizadas para construção dos modelos e os seus dados históricos – utilizados para o treinamento dos modelos – e as métricas utilizadas para avaliar cada um dos modelos. Foi construída também uma aplicação *web* totalmente responsiva, utilizando o *framework Next.js*, para conectar a *FastAPI* desenvolvida e servir como um ambiente de teste e consumo dos recursos da mesma.

O *frontend* foi hospedado na *Netlify* podendo então ser utilizado via online clicando [aqui](#). Mais detalhes sobre como utilizar aplicação e os recursos que ela oferece disponíveis em [Apêndice G](#).

5. DISCUSSÃO DE RESULTADOS

No final da fase de modelação, tanto em *Machine Learning* (ML) quanto nos modelos clássicos, foram selecionados apenas quatro modelos. Nesta secção serão identificados estes modelos e os seus desempenhos, que modelo teve melhores métricas globalmente, não apenas *ML* ou clássicos, a explicabilidade do melhor modelo, respostas as perguntas de investigação e mais alguns tópicos que evidenciam os resultados deste estudo.

5.1 Comparação Global

A otimização dos modelos apenas apresentou melhorias para o *CC-VAR* não tendo tido impacto nenhum sobre os modelos de *ML*. No final, foram selecionados apenas 4 modelos sendo 2 de cada abordagem. Estes modelos conseguiram todos superar o modelo *Naïve* que utiliza a média do conjunto de treino como previsão, como pode ser visto na tabela 5.1 com as métricas dos RMSE e MAE relativos.

Globalmente, o *Ridge* com as melhores *features* dos dois grupos de variáveis foi o modelo que apresentou melhor desempenho com o *RMSE* de 0,36, *MAE* de 0,31 e os erros relativos para as respetivas métricas de 59% e 68,9% contendo assim apenas pouco mais da metade dos erros do modelo *Naïve*. O *LightGBM* com as variáveis teóricas teve métricas equilibradas com os modelos clássicos com melhor desempenho no *RMSE* e pior no *MAE*.


Modelo	RMSE	MAE	Rel. RMSE*	Rel. MAE*
Naïve (média)	0,61	0,45	100%	100%
ARIMA(0,1,4)	0,52	0,37	85,2%	82,2%
CC-VAR	0,50	0,39	82%	86,7%
LightGBM	0,48	0,40	78,7%	88,9%
Ridge ★	0,36	0,31	59%	68,9%

Tabela 5.1 – Tabela comparativa dos modelos selecionados

5.2 Modelo Vencedor


O melhor modelo apresentou apenas cerca de uma décima de diferença em quase todas as métricas utilizadas para avaliar o desempenho do modelo nos conjuntos de treino e teste o que não evidencia a existência de *overfitting* no modelo (Figura 5.2.1).

Figura 5.2.1 — Ridge (Best_Features): Treino vs Teste



Ao se realizar as previsões no conjunto de teste foi possível verificar que os valores previstos pelo modelo se aproximavam muito dos valores reais num espaço de aproximadamente dois anos, o que pode indicar que os valores das métricas seleccionadas podem ter sido influenciados pelos meses dianteiros, e que mesmo após este período apesar dos valores previstos estarem afastados dos valores reais o modelo conseguia ainda capturar o padrão da série (Figura 5.2.2).

Figura 5.2.2 — Previsões vs. valores reais (teste)




No que diz respeito ao impacto que as variáveis preditoras tiveram sobre as previsões do modelo, como pode ser visto na figura 5.2.3, foi possível verificar que a

inflação nacional do mês anterior é o preditor que mais influencia no aumento da inflação com um aumento de $\sim 0,58$ pontos percentuais (pp) seguida da inflação dos Estados Unidos e isto acontece pelo facto da economia mundial estar interligada e as decisões da Reserva Federal Americana sobre taxas de juro influenciarem fortemente o mercado mundial.

Variáveis como o Índice de Preço do Produtor (PPI), no mês corrente, e a Exportação têm também impacto no aumento da inflação, mas, não tão significativos quanto as duas antes mencionadas, já o PPI do mês anterior tem um impacto totalmente contrário ao que se verifica no mês corrente sendo o que mais influencia na redução da inflação.

As variáveis referentes ao sentimento económico, Índice de Incerteza Política (EPU) e o Índice de Confiança do Consumidor (CCI) atuam como estabilizadores da inflação, tendo o seu aumento influencia na redução da inflação nacional.



5.3 Resposta às Questões de Investigação

Em resposta as perguntas de investigação feitas na primeira secção deste relatório o estudo realizado aponta que, sim, modelos de *ML* superam os modelos econométricos tradicionais, o melhor modelo global deste estudo foi um modelo de *ML* e o outro modelo teve um desempenho semelhante aos modelos econométricos.

A inércia inflacionista, a inflação dos Estados Unidos, os proxys da inflação nacional foram apontados por este estudo como os principais fatores determinantes da dinâmica inflacionista portuguesa E por último, as variáveis referentes ao sentimento

económico demonstraram-se fundamentais para garantir a boa capacidade preditiva do modelo construído.

6. CONCLUSÕES E RECOMENDAÇÕES

Os resultados obtidos neste estudo sugerem que os modelos de Machine Learning constituem uma alternativa viável e potencialmente superior aos modelos econométricos tradicionais na previsão da inflação em Portugal. A capacidade demonstrada pelos modelos de capturar a dinâmica da série inflacionista, mesmo em períodos em que os valores previstos se afastam dos valores observados, evidencia o potencial destas abordagens para complementar os instrumentos de previsão atualmente utilizados pelas instituições responsáveis pela análise económica.

Adicionalmente, a identificação da inércia inflacionista, da inflação dos Estados Unidos e de indicadores associados à evolução dos preços nacionais como os principais determinantes da inflação portuguesa reforça a necessidade de uma monitorização contínua destes fatores. Os resultados evidenciam igualmente a relevância dos indicadores de sentimento económico e de incerteza, nomeadamente o Índice de Incerteza de Política Económica e o Índice de Confiança do Consumidor, cuja inclusão contribuiu para melhorar a capacidade preditiva dos modelos.

Neste contexto, o Banco de Portugal poderá beneficiar da integração de técnicas de Machine Learning e de um conjunto mais alargado de indicadores económicos e comportamentais nos seus processos de previsão, permitindo complementar as metodologias tradicionais e apoiar de forma mais eficaz a análise da evolução futura da inflação.

Como desenvolvimentos futuros, perspetiva-se a combinação de previsões, mediante a qual as estimativas produzidas individualmente pelos modelos *Ridge*, *LightGBM*, *ARIMA* e *CC-VAR* seriam agregadas numa previsão *ensemble* ponderada, tirando partido das complementaridades entre especificações e reduzindo a dependência de qualquer modelo singular.

Adicionalmente, a incorporação de técnicas de Processamento de Linguagem Natural (PLN) constitui uma via promissora para enriquecer a capacidade preditiva do sistema, permitindo extrair sinais de sentimento a partir de fontes textuais, como comunicados de política monetária, notícias económicas ou relatórios institucionais, de modo a captar antecipadamente as expectativas dos agentes económicos antes de estas se materializarem nos indicadores macroeconómicos convencionais.

Por fim, propõe-se a adoção de um mecanismo de atualização automática do modelo, assente no re-treino periódico com os dados mais recentes à medida que se tornam disponíveis. Esta funcionalidade garantiria a adaptabilidade contínua do sistema às dinâmicas económicas em evolução.

REFERÊNCIAS BIBLIOGRÁFICAS

Banco Central Europeu. (2026). *What is inflation?* European Central Bank.
https://www.ecb.europa.eu/ecb-and-you/explainers/tell-me-more/html/what_is_inflation.en.html

Banco de Portugal. (2019). *O que é a inflação?* BPstat.
<https://bpstat.bportugal.pt/conteudos/paginas/1492>

Barigozzi, M., Lissona, C., & Tonni, L. (2024). Large datasets for the Euro Area and its member countries and the dynamic effects of the common monetary policy. *arXiv*.
<https://doi.org/10.48550/arXiv.2410.05082>

Diehn, S. A. (2022, junho 3). *Como a guerra na Ucrânia mudou o mundo em 100 dias*. DW. <https://www.dw.com/pt-002/como-a-guerra-na-ucr%C3%A2nia-mudou-o-mundo-em-100-dias/a-62027641>

Lagoa, S. (2017). Determinants of inflation differentials in the euro area: Is the New Keynesian Phillips Curve enough? *Journal of Applied Economics*, 20(1), 75–103.
[https://doi.org/10.1016/S1514-0326\(17\)30004-1](https://doi.org/10.1016/S1514-0326(17)30004-1)

MadreMedia & Lusa. (2018, setembro 15). *De Wall Street a Lisboa: Como a crise de 2008 atravessou o Atlântico*. 24 Notícias.
<https://24noticias.sapo.pt/economia/artigos/de-wall-street-a-lisboa-como-a-crise-de-2008-atravessou-o-atlantico>

Martins, T. G. (2025). *Inflation forecasting with machine learning using narrative features* [Dissertação de mestrado, ISEG – Universidade de Lisboa].
<https://repositorio.ulisboa.pt/entities/publication/97aafcac-68e0-4dc4-9f9b-5358a4339392>

McCracken, M. W., & Ng, S. (2016). FRED-MD: A monthly database for macroeconomic research. *Journal of Business & Economic Statistics*, 34(4), 574–589.
<https://doi.org/10.1080/07350015.2015.1086655>

Morão, H. (2024). An economic policy uncertainty index for Portugal. *Economic Analysis and Policy*.
<https://www.sciencedirect.com/science/article/pii/S2110701724000040>

Oancea, B., Simionescu, M., & Pospíšil, R. (2025). Do machine learning techniques outperform autoregressive distributed lag models in inflation forecasting? *Prague Economic Papers*, 34(4), 64. <https://doi.org/10.18267/j.pep.898>

Ramos, F. R. de J. (2021). *Data Science na modelação e previsão de séries económico-financeiras: Das metodologias clássicas ao Deep Learning* [Tese de doutoramento, ISCTE – Instituto Universitário de Lisboa]. <https://ciencia.iscte-iul.pt/publications/data-science-na-modelacao-e-previsao-de-series-economico-financeiras-das-metodologias-classicas-ao/82703>

Santos, A. R. G. N. V. (2019). *Forecasting inflation in Portugal by using machine learning techniques* [Dissertação de mestrado, Universidade de Lisboa e ISCTE – Instituto Universitário de Lisboa]. <https://repositorio.ulisboa.pt/entities/publication/0b4a76dd-f488-43e3-98eb-e2f75f106973>

Scikit-learn. (s.d.). 1.13. *Feature selection—Scikit-learn 1.8.0 documentation*. Scikit-learn. Obtido 6 de abril de 2026, de https://scikit-learn.org/stable/modules/feature_selection.html#univariate-feature-selection

FONTES DOS DADOS

Banco de Portugal. (2026). *Taxa de câmbio EUR/USD, fim de mês*. BPstat. <https://bpstat.bportugal.pt/serie/12532123>

Banco de Portugal. (2026, janeiro 14). *IPC total—Taxa de variação homóloga*. BPstat. <https://bpstat.bportugal.pt/serie/5721524>

Barigozzi, M., Lissona, C., & Tonni, L. (2026). *EA-MD-QD: Large Euro Area and Euro Member Countries datasets for macroeconomic research* [Conjunto de dados]. Zenodo. <https://zenodo.org/records/18804061>

EconDB. (s.d.). *Portugal – Producer Price Index*. EconDB. Obtido 20 de abril de 2026, de <https://www.econdb.com/series/PPIPT~TOYA/portugal-producer-price-index/>

Eurostat. (2026). *Producer prices in industry, domestic market—Portugal* [Conjunto de dados]. European Commission. https://ec.europa.eu/eurostat/databrowser/product/view/STS_INPPD_M

McCracken, M. W., & Ng, S. (s.d.). *FRED-MD and FRED-QD: Monthly and quarterly databases for macroeconomic research* [Conjunto de dados]. Federal Reserve Bank of St. Louis. Obtido <https://www.stlouisfed.org/research/economists/mccracken/fred-databases>

Morão, H. (2025). *EPU Portugal: Economic policy uncertainty index for Portugal* [Programa de computador]. GitHub. https://github.com/hmorao95/epu_portugal

OCDE. (2026). *Unemployment rate: Monthly, Portugal* [Conjunto de dados]. OECD Data Explorer. <https://data-explorer.oecd.org/>

Referências — APA consistente; fontes de dados + citações do estado da arte.

APÊNDICE A — REVISÃO DE LITERATURA

Este apêndice desenvolve o estado da arte resumido na Introdução, cobrindo os fundamentos teóricos da previsão da inflação, a literatura sobre *Machine Learning* (ML) aplicado a este problema e os estudos empíricos mais próximos deste trabalho.

A.1 Abordagens tradicionais e fundamentos teóricos

A previsão da inflação recorre há décadas a modelos econométricos. Os univariados, como o *AutoRegressive Integrated Moving Average* (ARIMA) e o *Seasonal ARIMA* (SARIMA), são usados como referência (*baseline*) pela capacidade de captar a autocorrelação temporal da série. Os vetoriais autorregressivos (VAR) são os preferidos por bancos centrais quando o objetivo é modelar relações dinâmicas entre vários indicadores. Os modelos ARDL (*Autoregressive Distributed Lag*) são mais flexíveis do que o VAR com conjuntos moderados de preditores que funcionam como referência econométrica nos estudos que comparam ML com econometria clássica (Oancea et al., 2025).

A seleção das variáveis preditoras assenta em dois quadros teóricos. A *New Keynesian Phillips Curve* (NKPC) estabelece que a inflação resulta dos custos marginais das empresas, aproximados pelo custo unitário do trabalho (ULC), e das expectativas futuras, o que confere um carácter *forward-looking* à dinâmica dos preços. O Modelo de Competição Imperfeita (ICM) acrescenta que as empresas fixam preços com uma margem (*markup*) sobre os custos marginais, pelo que salários, produtividade e lucros pretendidos também entram na equação. Lagoa (2017) documenta empiricamente, para a Zona Euro, que a inflação combina componentes *forward-looking* e *backward-looking*, com as expectativas como fator dominante, e que a NKPC isolada não explica os diferenciais entre países sem elementos do ICM.

Destes quadros teóricos decorre um conjunto de variáveis recorrente na literatura: indicadores de mercado de trabalho (desemprego, salários, ULC), medidas de atividade real (*output gap*, produção industrial), variáveis financeiras (taxas de juro, câmbio, índices bolsistas) e preços da energia como choques de oferta, a que se juntam desfasamentos da própria inflação para captar a inércia. Lagoa (2017) confirma, com dados da Zona Euro, o papel estatisticamente significativo da taxa de câmbio nos diferenciais de inflação, uma variável de particular peso para uma economia pequena e aberta como a portuguesa.

Estes modelos têm limitações conhecidas. Assumem relações lineares, tornam-se instáveis em períodos de quebra estrutural, como a crise de 2008, a pandemia e a invasão da Ucrânia em 2022 e lidam mal com conjuntos de dados de alta dimensão (McCracken & Ng, 2016).

A.2 Machine Learning na previsão da inflação

A partir de 2015, com mais dados disponíveis e maior poder computacional, o ML aplicado à previsão macroeconómica ganhou tração. McCracken & Ng (2016) mostram que fatores extraídos de grandes bases de dados macroeconómicas por Análise de Componentes Principais (PCA) têm capacidade preditiva para variáveis reais, mas que essa vantagem é menos consistente para a inflação, o que motivou a procura de métodos mais flexíveis.

Os modelos de regularização (*Lasso*, *Ridge*, *Elastic Net*) penalizam a complexidade e reduzem o sobreajustamento em conjuntos de alta dimensão. O *Elastic Net* é adequado quando há grupos de variáveis macroeconómicas correlacionadas, por equilibrar seleção e estabilidade dos coeficientes. Os modelos de *ensemble*, como o *Random Forest* e o *Gradient Boosting* (XGBoost, LightGBM), captam não-linearidades e interações sem especificação prévia e são robustos a *outliers*, embora menos interpretáveis. As redes neuronais recorrentes, em particular as *Long Short-Term Memory* (LSTM), têm vantagem em séries com dependências de longo prazo, mas exigem mais dados e recursos (Oancea et al., 2025). A combinação de previsões de vários modelos é, em geral, mais robusta do que qualquer modelo individual.

Os indicadores de sentimento e de incerteza têm entrado progressivamente neste tipo de estudos. Oancea et al. (2025) verificam que modelos sem estas variáveis falham em períodos de instabilidade e que a sua inclusão melhora a precisão. O Índice de Incerteza de Política Económica (EPU) para Portugal, de Morão (2024), capta as perceções de incerteza no contexto nacional, pois a incerteza altera as expectativas de empresas e famílias, com efeito direto sobre preços e consumo. Os indicadores de confiança da base EA-MD-QD (Barigozzi et al., 2024) incorporam informação prospectiva que os indicadores convencionais não têm.

A.3 Estudos empíricos de referência

Oancea et al. (2025) comparam ML com ARDL na previsão da inflação em países da Europa Central e Oriental em períodos de elevada volatilidade. O ML tende a superar o ARDL, sobretudo em horizontes curtos, a inclusão de índices de sentimento e da taxa de desemprego melhora a precisão e o uso de *TimeSeriesSplit* preserva a integridade temporal. O estudo cobre séries curtas num contexto de inflação extrema, ao contrário do presente trabalho, que cobre um período longo e estruturalmente diverso, de Janeiro de 2000 a Outubro de 2025.

No contexto português, Santos (2019) aplicou ML à previsão da inflação e é o antecedente mais direto deste trabalho. O presente estudo parte daí: base de dados mais extensa e comparação mais abrangente de modelos.

Martins (2025) combina dados macroeconómicos com variáveis narrativas extraídas de notícias para prever a inflação no Reino Unido. Os modelos híbridos superam os que usam apenas dados estruturados, o que aponta a incorporação de texto como extensão natural para trabalho futuro.

Barigozzi et al. (2024) introduzem a base EA-MD-QD e estudam a transmissão da política monetária do Banco Central Europeu (BCE) na Zona Euro. Identificam uma estrutura centro-periferia: os países periféricos, Portugal incluído, reagem com atraso. Cerca de 47% da variabilidade do Índice Harmonizado de Preços no Consumidor (HICP) português é determinada por fatores europeus comuns e 53% por dinâmicas internas, o que justifica incluir, em simultâneo, variáveis europeias e nacionais, com desfasamentos longos.

Lagoa (2017) documenta, com dados da Zona Euro, que Portugal e os países periféricos mantêm diferenciais de inflação persistentes face ao núcleo europeu, associados a diferenças nos custos laborais, nas expectativas e no ciclo económico.

A.4 Posicionamento do estudo

Santos (2019) mostrou que o ML é aplicável à previsão da inflação portuguesa. O presente trabalho parte dessa base: mais fontes de dados, período mais longo, e um conjunto mais alargado de modelos comparados numa estrutura avaliativa única.

Lagoa (2017) e Barigozzi et al. (2024) documentam que as dinâmicas inflacionistas portuguesas diferem do agregado europeu, o que sustenta a inclusão simultânea de variáveis europeias e nacionais com desfasamentos longos.


A diferença face aos estudos existentes está no âmbito da comparação: econométricos tradicionais e ML avaliados lado a lado, sobre um painel de alta dimensão que combina fontes europeias, norte-americanas e nacionais, com indicadores de incerteza e sentimento integrados, ao longo de um período que inclui três episódios estruturalmente distintos, a crise financeira, o choque pandémico e a desinflação pós-2022.

APÊNDICE B — ANÁLISE EXPLORATÓRIA

A análise exploratória foi conduzida sobre o *dataset* unificado com 310 observações mensais (jan/2000–out/2025) e 119 variáveis candidatas, antes de qualquer seleção ou modelação. O objetivo foi identificar padrões que informassem as decisões de preparação e modelação nos capítulos seguintes.

B.1 Análise da variável alvo

O histograma da taxa de inflação homóloga mostra uma distribuição aproximadamente unimodal, centrada próximo dos 2%, com assimetria positiva ligeira e caudas largas. A cauda direita estende-se até 10,1%, correspondente ao pico de 2022; a esquerda atinge -1,7%, registado durante a crise financeira de 2008 a 2014. A maioria das observações concentra-se no intervalo [0%, 4%], consistente com o objetivo de médio prazo do Banco Central Europeu (BCE). Os valores extremos não são *outliers* estatísticos no sentido clássico, mas episódios com causas identificáveis, choques exógenos de oferta e de procura, o que tem implicações para a modelação. Qualquer modelo treinado sobre esta série estará exposto a regimes macroeconómicos muito distintos.




A função de autocorrelação, apresentada na secção 2.3 do corpo do relatório, confirma que a série tem forte inércia: a autocorrelação no primeiro *lag* é de 0,977 e decai gradualmente até 0,4 no décimo segundo *lag*. A inflação presente é, em grande parte, determinada pela inflação recente, o que justifica a inclusão de *lags* da variável alvo como preditores nos modelos de *Machine Learning* (ML). A persistência também significa que

um *lag* 1 já capta uma fração relevante da variância da série, tornando a melhoria sobre ele um critério exigente para qualquer modelo.

B.2 Análise de correlação contemporânea em nível

A correlação de Pearson entre cada variável candidata e a inflação homóloga, calculada em nível sem transformações, serve como primeiro critério de triagem exploratória. As oito variáveis com maior correlação absoluta são as seguintes:

Rank	Variável	Pearson	Descrição
1	PPIPT_ppi	0,605	Índice de Preços no Produtor (PT)
2	TEMP_PT_ea-qd	0,490	Emprego total (PT)
3	GCF_PT_ea-qd	0,466	Formação bruta de capital (PT)
4	GS1_fred-md	0,465	Treasury yields 1 ano (EUA)
5	THOURS_PT_ea-qd	0,463	Horas trabalhadas (PT)
6	GS5_fred-md	0,458	Treasury yields 5 anos (EUA)
7	GFCF_PT_ea-qd	0,454	Formação bruta de capital fixo (PT)
8	IPDCOG_PT_ea-md	0,436	Produção industrial bens duradouros (PT)



A liderança do PPI é economicamente coerente: os preços no produtor precedem e transmitem-se aos preços no consumidor, pelo que uma correlação elevada em nível é

esperada. A presença dos *Treasury yields* americanos (GS1 e GS5) no topo do ranking, acima de variáveis portuguesas e europeias, reflete a sincronização do ciclo monetário global: o ciclo de subida de taxas da Reserva Federal precedeu e influenciou o do BCE, que por sua vez afetou a inflação portuguesa.

A variável TEMP_PT_ea-qd (emprego total) surge em segundo lugar, com Pearson=0,490. A correlação tem fundamento teórico pois, mais emprego implica maior procura agregada e pressão salarial, mas o teste de Causalidade de Granger não a confirmou como causal preditiva, sendo excluída do conjunto final por esse motivo (ver secção B.6).

O ranking em nível não captura a relevância preditiva de todas as variáveis. O caso mais evidente é o HICPNG_PT_ea-md (Harmonised Index of Consumer Prices, HICP, excluindo energia), que ocupa a posição 109 com Pearson=0,026, mas que a Causalidade de Granger e os coeficientes do modelo final *Ridge* identificam como um dos preditores mais relevantes. Esta divergência decorre da relação não-linear e desfasada entre esta variável e a inflação: em nível, a correlação linear é fraca, mas os *lags* de 12 meses têm forte poder preditivo, pois captam a estrutura de base de comparação da taxa homóloga.

B.3 Análise de formas funcionais

Para as variáveis com maior poder explicativo em nível, testaram-se quatro formas funcionais (linear, quadrática, cúbica e logarítmica) por regressão simples em amostra. O R^2 máximo obtido por cada variável e a forma que o produz são os seguintes:


Variável	Melhor forma	R^2
HICPNG_PT_ea-md	Cúbica	0,530
HICPIN_PT_ea-md	Cúbica	0,462
PPIPT_ppi	Cúbica	0,383
CUSR0000SAC_fred-md	Cúbica	0,378

A predominância de formas cúbicas indica que a relação entre os principais preditores e a inflação não é monotónica: para valores muito baixos ou muito elevados das variáveis explicativas, o efeito sobre a inflação inverte ou abranda. Uma subida do PPI, por exemplo, não se traduz proporcionalmente em inflação quando as margens das empresas absorvem parte do choque. O facto de o HICPNG_PT_ea-md atingir $R^2=0,530$

com forma cúbica, apesar de Pearson linear próximo de zero em nível, confirma que a correlação linear subestima sistematicamente a relação desta variável com a inflação. Este resultado constitui uma das motivações empíricas para a escolha de modelos de ML, que não impõem forma funcional prévia, ao contrário dos modelos VAR e ARIMA.


B.4 Análise bivariada de variáveis selecionadas

A relação entre o preço do petróleo e a inflação é positiva, mas com dispersão elevada, especialmente em valores extremos. Os episódios de 2008–2009 (colapso do preço na crise financeira) e de 2022 (pico por via da invasão da Ucrânia) são visíveis como pontos afastados da tendência central. A transmissão dos custos energéticos à inflação não é imediata, como mostra a análise de *lags* na secção B.5, pelo que a correlação contemporânea subestima a relação real.




A relação entre o Índice de Incerteza de Política Económica (EPU) e a inflação é instável ao longo do tempo. Em períodos de crise, nomeadamente 2010–2013 e 2020, a incerteza sobe enquanto a inflação cai ou se mantém baixa, produzindo correlação negativa. Em 2022 a relação inverte: incerteza e inflação sobem em simultâneo, pelo choque energético. Esta instabilidade indica que o EPU atua mais como variável de contexto do que como preditor direto, com poder explicativo limitado quando usado isoladamente, mas útil em combinação com outros preditores.

Figura B.4.2 — Taxa de Inflação vs Índice de Incerteza de Política



A relação entre o desemprego e a inflação é negativa, consistente com a Curva de *Phillips*: períodos de desemprego elevado, como 2012–2015, coincidem com inflação baixa ou negativa, e períodos de desemprego baixo, como 2019–2022, com inflação mais alta. A nuvem de pontos tem dispersão considerável, e em 2022 a inflação disparou apesar de o desemprego já estar em queda desde 2016, o que confirma que fatores de oferta podem sobrepor-se à dinâmica do mercado de trabalho.

Figura B.4.3 — Taxa de Inflação vs Desemprego (+15 anos)



B.5 Análise de desfasamentos temporais

Para cada variável candidata, identificou-se o *lag* em meses que maximiza a correlação de Pearson com a inflação homóloga. Os resultados para as variáveis mais relevantes são os seguintes:

Variável	Melhor lag	Pearson	Interpretação
PPIPT_ppi	5	0,723	Transmissão dos custos de produção ao consumidor
GCF_PT_ea-qd	5	0,527	Efeito desfasado da formação de capital sobre a procura
GFCF_PT_ea-qd	5	0,505	Formação bruta de capital fixo com desfasamento semelhante
GS1_fred-md	0	0,465	Treasury yields com efeito contemporâneo
GS5_fred-md	0	0,458	Treasury yields com efeito contemporâneo
UNEO25_PT_ea-md	12	0,436	Desemprego jovem com desfasamento longo (correlação negativa)

O caso do PPI é o mais relevante: a correlação sobe de 0,605 em nível para 0,723 com *lag* 5, um ganho de 19 pontos percentuais. Os custos de produção demoram em média cinco meses a repercutir-se nos preços ao consumidor, o que é consistente com os ciclos de negociação de contratos, margens de distribuição e revisões de preços. Este resultado fundamentou a inclusão do *lag* 5 do PPI nas *BEST_FEATURES* dos modelos de ML.


O desemprego jovem com *lag* 12 e correlação negativa de 0,436 reflete a dinâmica de médio prazo da Curva de Phillips: o mercado de trabalho demora cerca de um ano a transmitir os seus efeitos à inflação, no sentido esperado pela teoria. Os *Treasury yields* americanas têm o máximo de correlação no *lag* 0, o que sugere que os mercados financeiros incorporam as expectativas de inflação quase em tempo real.

B.6 Análise de variáveis com comportamento específico

O HICPNG_PT_ea-md tem o maior R^2 cúbico (0,530) e, ao mesmo tempo, ocupa a posição 109 no ranking de Pearson em nível. A série temporal sobreposta à inflação homóloga mostra que as duas séries co-movem de forma não-linear: em períodos de aceleração e desaceleração inflacionista, as variações do HICP excluindo energia antecipam as da inflação total com um padrão que a correlação linear em nível não consegue captar. No modelo *Ridge* final, o coeficiente desta variável é de 0,903 em valor absoluto, confirmando que a correlação de Pearson subestimou substancialmente a sua relevância preditiva.



O emprego total (TEMP_PT_ea-qd) apresenta Pearson=0,490 com a inflação, o que tem fundamento teórico: mais emprego implica maior procura agregada e pressão salarial, com efeitos sobre os preços. No entanto, correlação de Pearson em nível não equivale a causalidade preditiva. O teste de Causalidade de Granger ($p > 0,05$) não confirmou que o emprego total antecede a inflação de forma estatisticamente significativa, sendo a variável excluída do conjunto final.



APÊNDICE C — DETALHES DE PREPARAÇÃO

Este apêndice reúne os detalhes técnicos da *pipeline* de preparação referenciados no [capítulo 3](#): os métodos de interpolação selecionados para as variáveis trimestrais, as ordens dos modelos ARIMA usados no tratamento de *ragged edges*, as transformações de estacionarização das variáveis sem código predefinido nas bases de dados de origem e os desfasamentos selecionados pelo *Lasso*.

C.1 Interpolação das variáveis trimestrais

As variáveis provenientes da EA-QD têm frequência trimestral e foram convertidas para frequência mensal por interpolação. Para cada série, foram testados doze métodos e selecionado aquele que minimizava a diferença entre as médias da série original e da série interpolada. A Tabela C.1 indica o método retido para cada variável trimestral incluída no conjunto final.

Variável	Método
EMPENT_PT_ea-qd	Cúbica
DFGDP_PT_ea-qd	Spline
ULCIN_PT_ea-qd	Cúbica
EXPGS_PT_ea-qd	Cúbica
IMPGS_PT_ea-qd	Cúbica
GDP_PT_ea-qd	Linear

Tabela C.1 — Método de interpolação selecionado por variável trimestral


C.2 Tratamento de *ragged edges* (Auto-ARIMA)

As séries trimestrais mais recentes apresentam *ragged edges*: valores em falta nos meses finais da janela temporal que correspondem a meses ainda dentro do trimestre em curso. Para preencher estes valores, foi ajustado um modelo ARIMA a cada série afetada, com a ordem selecionada pelo Critério de Informação de Akaike (AIC). Um modelo ARIMA(p, d, q) combina um componente autorregressivo de ordem “p”, uma diferenciação de ordem “d” e um componente de médias móveis de ordem “q”; neste contexto, como o objetivo é extrapolar valores recentes e não estacionarizar, o parâmetro d é zero em todos os casos. A Tabela C.2 indica as ordens retidas por variável.

Variável	Ordem ARIMA(p, d, q)
CUSR0000SAC_fred-md	(8, 0, 0)
EMPENT_PT_ea-qd	(6, 0, 0)
DFGDP_PT_ea-qd	(4, 0, 2)
ULCIN_PT_ea-qd	(2, 0, 2)
EXPGS_PT_ea-qd	(8, 0, 0)
IMPGS_PT_ea-qd	(7, 0, 0)
GDP_PT_ea-qd	(7, 0, 0)

Tabela C.2 — Ordens ARIMA por variável com *ragged edges*

A título ilustrativo, a Figura C.2 mostra o resultado deste processo aplicado às exportações de bens e serviços (EXPGS_PT_ea-qd): a série mensal obtida combina os valores interpolados com os valores extrapolados pelo Auto-ARIMA nos meses finais.



C.3 Estacionarização de variáveis sem código predefinido

O PPI Portugal e a variável alvo foram tratados no corpo do relatório (secção 3.2). As duas variáveis restantes sem código de transformação predefinido são o Índice de Incerteza de Política Económica (EPU) e a taxa de desemprego proveniente da OCDE (*unemployment_up_15_unemployment*). Por não pertencerem às bases EA-MD ou FRED-MD, não dispõem de um código de transformação de referência e a transformação necessária foi determinada exclusivamente pelos testes ADF e KPSS.

O EPU foi testado em nível e classificado como estacionário (KPSS: estatística=0,106, $p=0,1$), não tendo sido aplicada qualquer transformação.

A taxa de desemprego da OCDE exigiu duas diferenciações para atingir estacionaridade. O teste KPSS aplicado à série duplamente diferenciada obteve estatística=0,142 e $p=0,057$, não rejeitando a hipótese de estacionaridade ao nível de 5%.

C.4 Desfasamentos selecionados pelo *Lasso*

Para cada variável explicativa, foram gerados os doze primeiros desfasamentos como candidatos a preditores. A regressão *Lasso* com regularização L1 forçou a zero os coeficientes dos desfasamentos menos relevantes. A Tabela seguinte lista os desfasamentos cujos coeficientes permaneceram não nulos e que foram retidos para a modelação de *Machine Learning* (ML).

Variável	Desfasamentos selecionados
GS1_fred-md	10
GS5_fred-md	12
OILPRICEx_fred-md_Eur	1, 2, 3, 4, 5, 6, 7, 12
CUSR0000SAC_fred-md	1, 2, 11, 12
PCEPI_fred-md	12
EMPENT_PT_ea-qd	12
REER42_PT_ea-md	6, 7, 8, 9, 10, 11, 12
HICPOV_PT_ea-md	12
HICPNEF_PT_ea-md	12
HICPSV_PT_ea-md	12
HICPNG_PT_ea-md	1, 3, 4, 12
DFGDP_PT_ea-qd	12
CCONFIX_PT_ea-md	1, 2, 11, 12
epu_pt_epu	6, 7, 8
GDP_PT_ea-qd	1, 2, 3, 4, 5, 12

ULCIN_PT_ea-qd	12
EXPGS_PT_ea-qd	2, 3
IMPGS_PT_ea-qd	2, 3
CCI_PT_ea-md	12
UNETOT_PT_ea-md	12
PPIPT_ppi	1, 2, 3, 4, 6, 7, 8, 9, 10, 11, 12
inflation_target	1

Tabela C.3 — Desfasamentos selecionados pelo Lasso por variável

APÊNDICE D — VARIÁVEIS SELECIONADAS

O conjunto final de variáveis tem 21 séries: 13 selecionadas computacionalmente por Causalidade de Granger e 8 adicionadas com base na teoria económica (NKPC e ICM). As tabelas seguintes listam cada variável com a sua descrição e fonte.

D.1 Variáveis selecionadas por Causalidade de Granger

O teste foi aplicado com maxlag=6 e limiar $p < 0,05$ (SSR F-test) sobre os dados de treino. As variáveis estão ordenadas por p-value crescente.

Variável	Descrição	Fonte	p-value
CUSR0000SAC_fred-md	CPI commodities — média das cidades dos EUA	FRED-MD	0,0004
OILPRICEx_fred-md_Eur	Preço do petróleo (USD convertido para EUR)	FRED-MD + BPStat	0,0005
HICPNG_PT_ea-md	HICP excluindo energia (PT)	EA-MD	0,0020
PCEPI_fred-md	PCE Price Index (EUA)	FRED-MD	0,0036
HICPSV_PT_ea-md	HICP excluindo serviços (PT)	EA-MD	0,0058
EMPENT_PT_ea-qd	Emprego nos serviços de entretenimento (PT)	EA-QD	0,0297
HICPNEF_PT_ea-md	HICP excluindo energia e alimentos (PT)	EA-MD	0,0333
DFGDP_PT_ea-qd	Deflator do PIB (PT)	EA-QD	0,0373
REER42_PT_ea-md	Taxa de câmbio real efetiva (PT)	EA-MD	0,0386
HICPOV_PT_ea-md	HICP total (PT)	EA-MD	0,0394
GS1_fred-md	Treasury yields a 1 ano (EUA)	FRED-MD	0,0405
CCONFIX_PT_ea-md	Custos na construção (PT)	EA-MD	0,0476
GS5_fred-md	Treasury yields a 5 anos (EUA)	FRED-MD	0,0489

D.2 Variáveis selecionadas por teoria económica

Estas variáveis foram adicionadas com base na *New Keynesian Phillips Curve* (NKPC) e no Modelo de Competição Imperfeita (ICM), descritos no [Apêndice A](#), por captarem dinâmicas do mercado de trabalho, da atividade real, do comércio externo e da incerteza de política económica.

Variável	Descrição	Fonte
PPIPT_ppi	Índice de preços na produção industrial (PT)	EconDB / Eurostat
epu_pt_epu	Índice de incerteza de política económica (PT)	Morão (2024)
ULCIN_PT_ea-qd	Custo unitário do trabalho na indústria (PT)	EA-QD
EXPGS_PT_ea-qd	Exportações de bens e serviços (PT)	EA-QD
IMPGS_PT_ea-qd	Importações de bens e serviços (PT)	EA-QD
CCI_PT_ea-md	Indicador de confiança do consumidor (PT)	EA-MD
GDP_PT_ea-qd	Produto interno bruto (PT)	EA-QD
UNETOT_PT_ea-md	Taxa de desemprego total (PT)	EA-MD

Tabela D.2 — Variáveis teóricas (NKPC e ICM)

APÊNDICE E — RESULTADOS DETALHADOS


E.1 Modelo ARIMA


Esta secção apresenta os detalhes da análise do modelo ARIMA(0,1,4): a identificação visual da ordem a partir das funções ACF e PACF, a validação dos resíduos dos dois modelos candidatos e as previsões no conjunto de teste.

E.1.1 Identificação da ordem

A seleção da ordem do modelo ARIMA assentou na pesquisa em grelha por critérios de informação, complementada pela análise visual das funções ACF e PACF da série diferenciada ($d=1$).

A ACF (Figura E.1.1) apresenta um valor significativo no lag 1 ($\sim 0,31$) e decaimento gradual até ao lag 5, com um pico negativo pronunciado no lag 12 ($\sim -0,35$). Este padrão é consistente com a presença de componentes de médias móveis e reflete a estrutura sazonal da taxa homóloga — a diferenciação de primeira ordem não elimina completamente o efeito de base anual. A PACF (Figura E.1.2) mostra um spike significativo no lag 1 ($\sim 0,31$) e valores dentro das bandas de confiança para a maioria dos lags seguintes, com exceção do lag 12 ($\sim -0,32$) e do lag 24 ($\sim -0,25$), que confirmam a influência da sazonalidade anual. O padrão conjunto — ACF decaindo com vários lags significativos, PACF com corte após o lag 1 — aponta para estrutura de médias móveis, o que sustenta a escolha do ARIMA(0,1,4).







E.1.2 Análise de resíduos

A análise de resíduos foi realizada para os dois melhores modelos candidatos — $ARIMA(0,1,4)$ e $ARIMA(3,1,0)$ —, que apresentam comportamentos muito semelhantes.

Os resíduos estandardizados do $ARIMA(0,1,4)$ (Figura E.1.3) oscilam em torno de zero sem tendência sistemática, com exceção de alguns valores mais extremos no período 2012–2014 e em 2022, associados a choques económicos documentados. O histograma aproxima-se da distribuição normal, com a estimativa KDE próxima da $N(0,1)$, embora as caudas sejam ligeiramente mais pesadas. O gráfico Q-Q confirma este comportamento: os quantis seguem a reta de referência no intervalo central, com desvios nas extremidades típicos de séries económicas sujeitas a choques. O correlograma dos resíduos não apresenta autocorrelações significativas em nenhum lag, o que confirma que o modelo capturou a estrutura temporal da série.




O ARIMA(3,1,0) (Figura E.1.4) apresenta um perfil de resíduos praticamente idêntico ao do ARIMA(0,1,4): oscilação sem padrão, distribuição aproximadamente normal com caudas ligeiramente pesadas e ausência de autocorrelação residual significativa. A semelhança entre os dois modelos nos diagnósticos de resíduos é consistente com a proximidade dos seus critérios de informação, sendo o ARIMA(0,1,4) o preferido por obter melhor *rank* médio de AIC, AICc e BIC.



E.1.3 Previsões no conjunto de teste

A Figura E.1.5 mostra as previsões recursivas de ambos os modelos no conjunto de teste. O ARIMA(0,1,4) e o ARIMA(3,1,0) produzem trajetórias quase indistinguíveis ao longo dos 28 meses, o que é coerente com a proximidade dos seus parâmetros. Ambos suavizam a variabilidade observada nos valores reais, em particular o pico de 3,6% em agosto de 2023, mas acompanham bem a tendência de descida e estabilização posterior. A partir de 2024, as previsões convergem para valores próximos de 2,5%, próximos dos observados.


Figura E.1.5 — Previsão recursiva no conjunto de teste



E.2 Modelo VAR


A Figura E.2 mostra as previsões dos três subconjuntos de variáveis testados no VAR. O subconjunto de variáveis teóricas mantém-se próximo dos valores reais ao longo de todo o período, com previsões estáveis entre 2% e 3% e uma ligeira subida no final consistente com a trajetória observada. O subconjunto computacional diverge acentuadamente para baixo a partir do final de 2023, atingindo cerca de 1% em meados de 2024 e aí permanecendo, o que revela incapacidade de capturar a dinâmica de estabilização da inflação. O subconjunto *best features* diverge em sentido oposto, com uma trajetória crescente que ultrapassa 4,5% em outubro de 2025, evidenciando instabilidade neste subconjunto quando aplicado ao VAR. As variáveis teóricas foram o subconjunto selecionado para o modelo final, com lag=1 e tendência constante e linear.

Figura E.2 — Previsões do VAR (variáveis teóricas) no conjunto de teste



E.3 Modelo CC-VAR

A Figura E.3 mostra as previsões dos três subconjuntos no CC-VAR. O subconjunto de variáveis teóricas mantém uma trajetória estável próxima de 2,5%, acompanhando bem os valores reais sem divergência. O subconjunto computacional sobe progressivamente a partir de meados de 2024, atingindo cerca de 4,2% no final do período — um comportamento mais moderado do que no VAR, o que sugere que a redução de dimensionalidade via ACP atenua parcialmente a instabilidade. O subconjunto *best features* apresenta comportamento intermédio, com subida gradual até ~3,3%. Em todos os casos, o subconjunto teórico é o mais estável e o mais próximo dos valores observados, confirmando a escolha do modelo final com variáveis teóricas, lag=1, tendência constante e linear, e 4 componentes principais que explicam 82% da variância.



E.4 Melhores modelos de ML por grupo de variáveis

Os modelos foram ordenados por rank médio das métricas *RMSE*, *MAE* e *WAPE* no conjunto de teste. As tabelas seguintes apresentam os cinco melhores por grupo.

Tabela E.1 — Top 5 modelos — variáveis teóricas

Rank	Nível de lags	Modelo	RMSE teste	MAE teste	WAPE teste	Sobreajustamento
1	10	LightGBM	0,48	0,40	0,162	Sim
2	11	LightGBM	0,63	0,50	0,204	Sim
3	7	RF-MSE	0,70	0,57	0,235	Sim
4	8	RF-MSE	0,69	0,58	0,237	Sim

5	9	<i>LightGBM</i>	0,68	0,58	0,240	<i>Sim</i>
---	---	-----------------	------	------	-------	------------

Tabela E.2 — Top 5 modelos — variáveis computacionais

Rank	Nível de lags	Modelo	RMSE teste	MAE teste	WAPE teste	Sobreajustamento
<i>1</i>	<i>12</i>	<i>Ridge</i>	<i>0,46</i>	<i>0,35</i>	<i>0,144</i>	<i>Sim</i>
<i>2</i>	<i>11</i>	<i>Ridge</i>	<i>0,49</i>	<i>0,37</i>	<i>0,150</i>	<i>Sim</i>
<i>3</i>	<i>1</i>	<i>Ridge</i>	<i>0,51</i>	<i>0,42</i>	<i>0,172</i>	<i>Sim</i>
<i>4</i>	<i>9</i>	<i>Ridge</i>	<i>0,57</i>	<i>0,43</i>	<i>0,176</i>	<i>Sim</i>
<i>5</i>	<i>8</i>	<i>Ridge</i>	<i>0,57</i>	<i>0,43</i>	<i>0,177</i>	<i>Sim</i>

APÊNDICE F — OTIMIZAÇÃO DO VAR E CC-VAR

Este apêndice reúne os detalhes da otimização dos modelos VAR e CC-VAR referenciados na secção 4.4: os parâmetros seleccionados por subconjunto e as métricas de treino e teste para cada configuração.

F.1 Modelo VAR

A otimização do VAR foi realizada por Optuna com 300 *trials*, com validação *walk-forward* de 3 *folds* e horizonte de 12 meses, exclusivamente sobre o conjunto de treino. Os parâmetros pesquisados foram o número de *lags* e o tipo de tendência determinística (nc, c, ct). A Tabela F.1 indica os parâmetros seleccionados e o AIC do modelo ajustado para cada subconjunto; todos os modelos são estáveis (raízes do polinómio característico fora do círculo unitário).

Subconjunto	Lag	Tendência	AIC
Teóricas	1	ct	-15,096
Computacionais	3	ct	-19,595
Best Features	2	ct	-17,787

Tabela F.1 — Parâmetros otimizados do VAR por subconjunto

A Tabela F.2 apresenta as métricas de treino e teste para os três subconjuntos. O subconjunto de variáveis teóricas é o único que não exhibe sobreajustamento em nenhuma métrica e obtém os melhores resultados no teste em todas as dimensões, sendo seleccionado como modelo final. Os subconjuntos computacionais e *best features* apresentam erros de teste elevados e próximos do limiar de sobreajustamento, o que é consistente com a instabilidade visível nas previsões da Figura E.2.

Subconjunto	MAE treino	MAE teste	RMSE treino	RMSE teste	WAPE treino	WAPE teste	Sobreajustamento
Teóricas	1,182	0,395	1,510	0,510	0,527	0,162	Não
Computacionais	1,004	1,152	1,188	1,253	0,447	0,473	Não
Best Features	1,021	1,181	1,242	1,420	0,455	0,485	Sim (MAE)

Tabela F.2 — Métricas de treino e teste do VAR por subconjunto

F.2 Modelo CC-VAR

A otimização do CC-VAR envolveu três dimensões: a variância explicada retida pela ACP (intervalo 50%–95%), o número de *lags* e o tipo de tendência. O processo foi realizado por Optuna com 300 *trials* e validação *walk-forward* de 3 *folds* com horizonte de 12 meses. Para garantir robustez ao ponto de partida, foram testadas 500 *seeds*, com paragem antecipada ao atingir 15 *trials* consecutivos sem melhoria do melhor *score* global (média de MAE, RMSE e WAPE). A seed 0 produziu o melhor resultado. A Tabela F.3 indica os parâmetros selecionados por subconjunto.

Subconjunto	Lag	Tendência	Variância explicada	Componentes	AIC
Teóricas	1	ct	82,0%	4	−5,218
Computacionais	5	ct	88,3%	7	−5,935
Best Features	6	ct	78,4%	4	−4,363

Tabela F.3 — Parâmetros otimizados do CC-VAR por subconjunto

A Tabela F.4 apresenta as métricas de treino e teste. O subconjunto de variáveis teóricas obtém os melhores resultados no teste e é o único sem sobreajustamento em nenhuma métrica, sendo selecionado como modelo final. O subconjunto computacional apresenta sobreajustamento no MAE; o *best features* não tem sobreajustamento mas fica claramente atrás das variáveis teóricas em todas as métricas de teste.

Subconjunto	MAE treino	MAE teste	RMSE treino	RMSE teste	WAPE treino	WAPE teste	Sobreajustamento
Teóricas	0,970	0,390	1,367	0,496	0,432	0,160	Não
Computacionais	0,948	1,161	1,142	1,285	0,423	0,477	Sim (MAE)
Best Features	1,053	0,730	1,244	0,856	0,471	0,300	Não

Tabela F.4 — Métricas de treino e teste do CC-VAR por subconjunto

G — NAVEGAÇÃO NO DASHBOARD (DEPLOYMENT)

Este apêndice serve como um guia de navegação na aplicação web desenvolvida para a implementação do modelo construído.



Figura G.1 – Barra de navegação

A barra de navegação permite navegar entre as diferentes páginas disponíveis na aplicação web desde o Painel até as Variáveis utilizadas para a construção dos modelos. Por lá é possível alterar o horizonte de previsão, tendo disponíveis apenas três opções – 1, 3 e 12 meses – e é possível também alterar o modelo a ser visualizado como alterar para o modo escuro.




Figura G.2 – Modelos disponíveis na aplicação web

Clicando no campo para seleção do modelo são apresentados os diferentes modelos treinados e fica destacada a azul o modelo que está atualmente selecionado tal como é ele que aparece logo no campo de modelo.




Figura G.3 – Painel parte 1

A página principal da aplicação é o Painel, na figura acima é possível ver parte da informação disponível nesta página. Ela tem logo no início a informação sobre o horizonte temporal selecionado, 3 meses, a previsão atual do modelo selecionado tendo em conta o cenário base – que dita que os valores verificados no último mês disponível nos dados de treino voltam a ser visualizados no 3 meses seguintes (horizonte temporal selecionado), que corresponde ao valor previsto para o terceiro mês a seguir ao último mês do conjunto utilizado para treinar o modelo final (Outubro de 2025), o melhor modelo, esta informação é estática, ou seja, não depende do modelo selecionado.

A variação da previsão corresponde à diferença entre a previsão atual e a previsão para o mês anterior. A confiança corresponde ao dobro do *MAE* do modelo selecionado, neste caso, o modelo selecionado é o *Ridge* pelo que a confiança é $0,28 \times 2 = 0,56$ arredondado por excesso.



Figura G.4 – Painel parte 2

Dando *scroll* no painel é possível ver o gráfico que mostra parte dos valores ajustados pelo modelo selecionado e a previsão do modelo (depois da linha horizontal de Treino) para o horizonte temporal selecionado, a preto estão os valores reais e a azul os valores ajustados/previstos. Apenas os valores reais que antecedem a linha horizontal de treino foram utilizados para a construção dos modelos.




Figura G.5 – Painel parte 3

Mais um *scroll* e é possível ver o desempenho dos diferentes modelos treinados tendo destaque para o melhor modelo.




Figura G.6 – Painel parte 4

Num último *scroll* no painel é possível ver a importância das variáveis na previsão da inflação para o modelo selecionado.




Figura G.7 – Modelos parte 1




Figura G.8 – Modelos parte 2

Na barra de navegação, clicando em Modelos é carregada esta nova página que começa apresentando a previsão de cada um dos modelos para os próximos 12 meses e o desempenho que cada um dos modelos teve sobre o conjunto de teste na fase de seleção dos modelos.




Figura G.9 – Modelos parte 3

Dando 2 *scrolls* na página de modelos é possível ver a previsão dos próximos 12 meses de todos os modelos, os valores ajustados de cada um e a inflação histórica. Acima é possível selecionar que modelos omitir ou apresentar no gráfico.




Figura G.10 – Modelos parte 4




Figura G.11 – Modelos parte 5

Mais um *scroll* e é possível ver graficamente o desempenho de cada modelo. E com último os resíduos dos valores ajustados dos modelos face aos valores reais.




Figura G.12 – Análise de cenários parte 1




Figura G.13 – Análise de cenários parte 2

Na barra de navegação, clicando em Análise de Cenários é aberta uma nova página do site onde é possível selecionar os diferentes cenários predefinidos, como foi referido no corpo deste relatório e ver mais abaixo o impacto de cada cenário sobre a inflação futura.

É possível ver também em cada cenário que choques foram aplicados sobre o cenário base para os “criar” e eles são ainda ajustáveis caso o usuário deseje criar um cenário personalizado.




Figura G.14 – Análise de cenários parte 3

Ainda na mesma página é possível ver o impacto do cenário (azul), o cenário base (cinza tracejado) e o histórico.



Figura G.15 – Variáveis parte 1



Figura G.16 – Variáveis parte 2




Figura G.17 – Variáveis parte 3




Figura G.18 – Variáveis parte 4




Figura G.19 – Variáveis parte 5

Na última página da aplicação *web* é possível ver as séries utilizadas para a construção do modelo selecionado e observar como elas se relacionam com a variável alvo, ver a série isolada, a sua *ACF* e a correlação de cada uma das variáveis entre si.