


Contextualização

O que é a Inflação?

A inflação corresponde à subida generalizada e contínua do nível de preços, com impacto direto no poder de compra das famílias, nas decisões de consumo, de investimento e, na política monetária.


É refletida pelo Índice de Preços no Consumidor (IPC), calculado mensalmente, em Portugal pelo Instituto Nacional de Estatística. O alvo deste estudo trata-se, assim, da Taxa de Inflação Homóloga que mede a variação percentual do nível geral de preços face ao mesmo mês do ano anterior.

A nível europeu, é utilizado o Índice Harmonizado de Preços no Consumidor (HIPC), calculado pelo Eurostat em colaboração com o Banco Central Europeu (BCE), permitindo comparações entre países da Zona Euro através de uma metodologia comum.



Episódios Determinantes

- ▼ 2008 – 2014 → A **Crise Financeira Global** provocou uma contração da procura e a resposta dos bancos centrais levaram Portugal à deflação (mín. -1,7%).
- ▲ 2020 – 2022 → A **COVID-19** e a **Invasão à Ucrânia** provocaram desequilíbrios nas cadeias de abastecimento e choques energéticos fizeram a inflação atingir 10.1%, máximo desde os anos 90.
- 2023 – 2025 → A **subida das taxas de juro** pelo BCE e a normalização das cadeias de abastecimento, levou a uma trajetória descendente gradual, convergindo até aos valores próximos do objetivo, definido pelo BCE, de 2%.



Este estudo teve como objetivo responder às seguintes **questões de investigação**:

- Os modelos de *Machine Learning* (ML) superam os modelos econométricos tradicionais na previsão da inflação em Portugal?
- Quais são os principais fatores e variáveis determinantes da dinâmica inflacionista portuguesa?
- A inclusão de indicadores de sentimento e incerteza económica melhora o desempenho preditivo dos modelos?

Dados e Metodologia

A metodologia que sustentou e guiou esta investigação consiste no CRISP-DM (*Cross-Industry Standard Process for Data Mining*). As suas fases foram operacionalizadas através das seguintes técnicas:



Recolha de Dados

Esta fase inicial reflete a recolha de variáveis macroeconómicas que são alvo de estudo para prever a inflação. Os dados recolhidos proveem de 6 fontes distintas:

- **Banco de Portugal**: Variável em estudo e a taxa de câmbio EUR/USD histórica, para converter variáveis monetárias;
- **Euro Area (EA)**: Variáveis mensais e trimestrais relativas a Portugal;
- **Federal Reserve Bank of St. Louis (FRED)**: Variáveis da economia Americana que afetam a economia global;
- **Artigo de Investigação** (Morão, H. 2024): Obtido o Índice de Incerteza Política para Portugal;
- **OECD**: Taxa de desemprego mensal em Portugal para a população com 15 anos ou mais;
- **EuroStat**: Índice de Preços no Produtor para Portugal.

Após a integração dos dados foi feito *Feature Engineering* e obteve-se, assim:

310 observações


Janeiro 2000 a Outubro 2025

121 variáveis (55 mensais + 65 trimestrais + alvo)

Análise Exploratória dos Dados


A Taxa de Inflação Homóloga não apresenta tendência determinística nem sazonalidade. A série é não estacionária dado o p-value > 5% do teste *Augmented Dickey-Fuller* (ADF), o que indica a necessidade de diferenciação (d=1) nos modelos econométricos.

	Média	Std	Mín	Máx	ADF (p-value)
Taxa de Inflação	2,2	1,97	-1,7	10,1	0,09



Verifica-se uma forte inércia inflacionista com uma autocorrelação igual a 0,98 para o 1º lag, decaindo gradualmente até 0,3 no 12º lag. Este comportamento motivou a inclusão da memória passada recente como preditor nos modelos ML.

A taxa de variação homóloga do Índice de Preços no Produtor (PPI) apresenta uma correlação de *Pearson* de $\rho=0,6$ com a inflação → enquadrada com a teoria económica (custos de produção → ajustes nos preços). O impacto é ainda mais significativo com o desfaseamento de 5 meses ($\rho=0,72$), refletindo a demora na transmissão ao consumidor.




Preparação dos Dados

Todas as decisões metodológicas foram aplicadas primeiro aos dados de treino e só depois no teste, prevenindo *data leakage*.

Divisão do Dataset	
Treino (91%) Janeiro 2000 → Junho 2023 282 meses	Teste (9%) Julho 2023 → Outubro 2025 28 meses

Tratamento de Valores Omissos

Este passo foi necessário para converter as variáveis trimestrais em mensais. Foram utilizadas técnicas de interpolação, sendo selecionados os métodos que permitiam reduzir a diferença entre as médias de ambas as séries. Para os *ragged edges*, valores omissos no final da série devido ao atraso da publicação trimestral, foram utilizados modelos ARIMA.



Seleção das Variáveis

Foram selecionadas variáveis pela teoria económica e de forma computacional. Para a seleção computacional foi utilizada a Causalidade de Granger como critério final, com base nos primeiros 6 lags, aplicada sobre séries estacionarizadas. Outros métodos foram explorados como análise prévia:

Correlação de *Pearson*

Correlações lineares entre as variáveis

Select Kbest

Seleção das K variáveis com maior score estatístico

Stepwise Models

Seleção sequencial de variáveis com base na melhoria do modelo

Variáveis Teóricas (8)


- Índice de Incerteza Política
- Preço Unitário Laboral
- Índice de Confiança do Consumidor
- PIB
- Desemprego
- Índice de Preços no Produtor
- Exportações de Bens e Serviços
- Importações de Bens e Serviços

Fundamentação

- New Keynesian Phillips Curve*
- Teoria da Competição Imperfeita

Variáveis Computacionais (13)


- HIPC: Total; Excluindo Energia; Energia e Alimentos; Serviços
- Rendimento dos Títulos do Tesouro de 1 e de 5 anos
- Preço do Petróleo em Euros
- Índice de Preços do Consumidor para todos os Consumidores Urbanos US
- Índice de Preços do Consumo Pessoal
- Empregos no setor de Entretenimento e outros serviços
- Taxa de Câmbio Real Efetiva
- Deflator do PIB
- Custos na Construção



Modelação


Para responder às questões de investigação, foram treinados e avaliados modelos econométricos tradicionais, como: *AutoRegressive Integrated Moving Average* (ARIMA), *Vector Autoregression* (VAR), *Common Component-VAR*, e de *Machine Learning*: *Random Forest*, *Light Gradient-Boosting Machine* (*LightGBM*) e *Ridge*.

Os modelos multivariados foram testados em três subconjuntos de variáveis: teóricas, computacionais e um terceiro, composto pelas variáveis mais importantes identificadas por *feature importance*. Todas as combinações foram avaliadas por MAE, RMSE, WAPE e métricas relativas ao modelo *Naive*.




Modelo	RMSE	MAE	Relative RMSE (%)	Relative MAE (%)
Naive (média)	0,52	0,39	100	100,0
ARIMA(0,1,4)	0,52	0,37	100	94,9
CC-VAR	0,5	0,39	96,2	100,0
LightGBM	0,48	0,4	92,3	102,6
Ridge	0,34	0,28	65,4	71,8

O Modelo *Naive* é a previsão com base na média histórica – as métricas relativas correspondem à divisão do respetivo valor de cada modelo pelo valor do *Naive*. O *Ridge* obteve o melhor desempenho absoluto no conjunto de teste, superando os modelos econométricos tradicionais testados, com MAE de 0,28 p.p. → erro economicamente relevante para decisões de política monetária.



Explicabilidade



A memória da inflação é o preditor dominante, confirma a forte inércia inflacionista. O índice de incerteza política e a confiança do consumidor têm influência negativa – maior incerteza e menor confiança moderam a procura e, consequentemente, a Inflação.

Git hub

